

Yapay Zekâ Tabanlı Klinik Karar Destek Sistemleri

Ders Notları ve Sunum Kaynak Metni

Prof. Dr. Utku Köse

Süleyman Demirel Üniversitesi, Mühendislik ve Doğa Bilimleri Fakültesi, Bilgisayar Mühendisliği
Bölümü, Isparta, Türkiye

Yapay Zekâ Uygulama ve Araştırma Merkezi (YAZEM) Müdürü, Isparta, Türkiye

University of North Dakota, Grand Forks, ABD

Universidad Panamericana, Meksiko, Meksika

Vel Tech University, Chennai, Hindistan

IEEE Senior Member, ACM Professional Member

utkukose@sdu.edu.tr

Sağlık Bilimlerinde Teknoloji ve Yapay Zekâ Okuryazarlığı Eğitimi, Akdeniz Üniversitesi, 16 Eylül 2026

Özet

Bu metin, Sağlık Bilimlerinde Teknoloji ve Yapay Zekâ Okuryazarlığı Eğitimi kapsamında verilen kırk beş dakikalık oturumun kaynak metnidir. Klinik karar destek sistemlerinin tanımından başlanmakta, böyle bir sistemin yazılım olarak hangi aşamalardan geçerek kurulduğu ele alınmakta, sahada neden başarısız olduğu bağımsız dış doğrulama bulguları üzerinden tartışılmakta ve güvenilirliği belirleyen ölçütler ile düzenleyici çerçeve özetlenmektedir. Geliştirme aşamaları, 18 Eylül 2026 tarihli atölye çalışmasının not defterleriyle tek tek eşleştirilmiştir.

Anahtar kavramlar: Klinik karar destek sistemi, yazılım yaşam döngüsü, dış doğrulama, kalibrasyon, pozitif kestirim değeri, veri sızıntısı, açıklanabilir yapay zekâ, tıbbi cihaz yazılımı.

Sunum akışı

Bölüm	Anahtar mesaj
Giriş ve politika bağlamı	Sağlıkta yapay zekâ okuryazarlığı ulusal bir hedeftir
Karar destek sistemi nedir	Sistem teşhis koymaz, klinik dikkati yönlendirir
Sistem yazılımsal olarak nasıl kurulur	On üç aşamanın on ikisi atölyede bir deftere karşılık gelir
Neden başarısız oluyorlar	Dış doğrulaması olmayan bir başarıım iddiası yalnızca bir iddiadır
Güvenilir kılan nedir	Kalibrasyon, açıklanabilirlik ve raporlama standartları birlikte değerlendirilir
Düzenleyici çerçeve	Müstakil kanun yokluğu sorumluluk boşluğu anlamına gelmez
Atölyeye köprü	Üretken yapay zekâ kod yazar, değerlendirme sorumluluğu

Bölüm	Anahtar mesaj
	kullanıcıda kalır

1. Giriş: Politika bağlamı ve dersin amacı

Türkiye Yapay Zekâ Eylem Planı (2026-2030), 2026/9 sayılı Cumhurbaşkanlığı Genelgesi ile 18 Ağustos 2026 tarihli ve 33344 sayılı Resmî Gazete'de yayımlanarak yürürlüğe girmiştir [1]. Plan; insan odaklılık, güvenilirlik, etik sorumluluk, dijital egemenlik ve sürdürülebilir kalkınma ilkeleri üzerine kurulmuş olup 2021-2025 dönemini kapsayan Ulusal Yapay Zekâ Stratejisi'nin yerini almıştır [1]. İnsan kaynağı başlığı altında 81 ilde yürütülecek bir ulusal yapay zekâ okuryazarlığı programı öngörülmektedir [2].

Sağlık alanında yapay zekâ okuryazarlığının teknik beceriden önce gelen bir boyutu bulunur: Hatanın bedelini ödeyen taraf, sistemi kuran taraf değildir. Bu nedenle dersin eksen, bir karar destek sisteminin nasıl kurulduğu ile nasıl değerlendirileceği arasında kurulmuştur. İki soru birbirinden ayrılamaz; aşamaları bilmeyen bir kullanıcı, hangi aşamada hangi hatanın yapıldığını da göremez.

Kodlama işi 18 Eylül atölyesinde üretken yapay zekâ araçlarına büyük ölçüde devredilecektir. Devredilemeyen iş, hangi kodun isteneceğine karar vermek ve gelen kodu denetlemektir.

2. Klinik karar destek sistemi nedir

2.1. Tanım ve beş doğru

Klinik karar destek sistemi, klinik bir kararı iyileştirmek amacıyla doğru bilgiyi doğru kişiye doğru biçimde doğru kanaldan doğru zamanda ulaştıran sistem olarak tanımlanır. Literatürde bu beş bileşen karar desteğin beş doğrusu olarak anılır [3, 4].

Beş bileşenin aynı anda sağlanmaması durumunda sistem teknik açıdan çalışsa bile klinik açıdan işlevsiz kalır. Doğru bilgi yanlış kullanıcıya ulaştığında gürültüye, doğru kullanıcıya karar anından sonra ulaştığında yalnızca bir kayda dönüşür. Bu nedenle bir sistemin değerlendirilmesinde model başarımları kadar iş akışına yerleşme biçimi de belirleyicidir.

2.2. İki aile: Bilgi tabanlı ve veri güdümlü sistemler

Bilgi tabanlı sistemler klinik kılavuzlardan çıkarılan açık kurallar üzerine kuruludur. İlaç etkileşimi uyarıları, doz sınırı denetimleri ve alerji kontrolleri bu aileye girer. En güçlü yanları, uyarının gerekçesinin her zaman okunabilir olmasıdır; denetlenebilir ve versiyonlanabilir yapıdadırlar. Zayıf yanları ise kural sayısı arttıkça bakımın güçleşmesi ve klinik nüansın yakalanamamasıdır.

Veri güdümlü sistemler geçmiş hasta verisinden örüntü öğrenen modellere dayanır. Sepsis risk skorları, yeniden yatış tahmini ve tıbbi görüntüde lezyon işaretleme bu gruptadır. Bu sistemler kimsenin açıkça formüle edemediği örüntüleri yakalayabilir. Buna karşılık öğrendikleri şey, eğitildikleri kurumun kayıt alışkanlıkları veya cihaz altyapısı olabilir ve sistem başka bir merkeze taşındığında başarımları düşer.

Sahadaki sistemlerin çoğu melez yapıdadır: Öğrenen bir skor, kural tabanlı bir eşiğin arkasına yerleştirilir. Sorumluluğun nasıl kurulacağı iki ailede farklıdır ve bu ayrım düzenleyici değerlendirmede de karşımıza çıkar.

2.3. Sistem anatomisi

Bir klinik karar destek sistemi sekiz halkalı bir zincir olarak düşünülebilir. Zincir veri kaynağı ile başlar; öznitelik üretimi, model, eşik ve karar mantığı, arayüz, klinisyen kararı, klinik eylem ve nihayet izleme ile geri besleme halkalarıyla tamamlanır.



Yayımlanan başarımlar üçüncü halkaya aittir. Klinik fayda dördüncü halkadan sonra oluşur.

Şekil 1. Klinik karar destek sisteminin sekiz halkası ve geri besleme döngüsü.

Yayınlarda raporlanan başarımlar genellikle yalnızca üçüncü halkaya, yani modelin kendisine aittir. Klinik fayda ise dördüncü halkadan sonrasında oluşur. Model başarımları ile klinik fayda birbirinin yerine geçmez.

2.4. Klinisyenin sistemdeki yeri

Karar destek sisteminin ürünü bir teşhis değil, bir dikkat tahsisidir. Sistem, hastada belirli bir tablonun bulunduğunu ilan etmez; ilgili hastaya öncelik verilmesini önerir. Aradaki fark hem klinik hem hukuki açıdan belirleyicidir.

Amerika Birleşik Devletleri'nde 21st Century Cures Act ile Federal Gıda, İlaç ve Kozmetik Kanunu'na eklenen 520(o)(1)(E) maddesi, bir karar destek yazılımının tıbbi cihaz tanımı dışında kalabilmesi için dört ölçüt arar. Bu ölçütlerden biri, sağlık profesyonelinin önerinin dayanağını bağımsız olarak gözden geçirebilmesidir [5, 6]. Açıklanabilirlik bu çerçevede yalnızca etik bir tercih değil, cihaz sayılıp sayılmamanın eşiğidir.

3. Sistem yazılımsal olarak nasıl kurulur

Bir klinik karar destek sisteminin kurulması on üç aşamaya ayrılabilir. Aşamaların ilk on ikisi 18 Eylül atölyesinde bir not defterine karşılık gelir; on üçüncüsü atölye kapsamı dışında kalır ve burada gerekçesiyle ele alınır.

Geliştirme aşaması

Atölye defteri

1. Karar anı ve sabitlerin tanımı	NB1
2. Veriye ulaşma, kohort tanımı, ilk bakış	NB1
3. Temizleme	NB2
4. Hasta düzeyinde ayırım	NB2
5. Modele uygun biçime çevirme	NB2
6. Model kurma ve öğretme	NB3
7. Tahmin üretme ve eşik seçimi	NB3
8. Dürüst ölçüm	NB3
9. Kararın gerekçelendirilmesi	NB4
10. Güvenlik bariyerleri	NB5
11. Uyumluluk raporu	NB5
12. Arayüz ve devreye alma	NB6
13. Devreye alma sonrası izleme	—

Son aşama atölye kapsamı dışındadır ve derste gerekçesiyle ele alınır.

Şekil 2. Geliştirme aşamaları ve karşılık geldikleri atölye defterleri.

3.1. Karar anı, veri ve temizleme: Aşama 1 ile 3

Birinci aşama karar anının tanımlanması ve programın sabitlerinin yazılmasıdır. Karar anı, sistemin çıktı ürettiği tam zamandır ve sistemin kullanabileceği bilginin sınırını çizer. Atölyenin ortak senaryosunda bu an yoğun bakıma kabulden altı saat sonrasındır. Hedef eşiği, veri kaynağı ve tekrar üretilebilirlik sayısı da bu aşamada tanımlanır. Bu değerlerin kodun başında ve tek bir yerde durması bir biçim tercihi değildir; klinik bir sistemde eşikler denetime tabidir ve görünür olmaları gerekir.

İkinci aşama veriye ulaşma ve kohortun tanımlanmasıdır. Kohort tanımı, sistemin hangi hastaları kapsadığı kadar hangilerini kapsam dışında bıraktığını da içerir. Ortak senaryoda altı saatten kısa yatışlar dışarıda bırakılır, çünkü bu hastalar karar anına hiç ulaşmaz. Sızıntıya karşı ilk koruma da burada kurulur: Yatış süresi ve çıkış saati gibi ancak hasta ayrıldıktan sonra bilinen sütunlar, veri daha programa alınırken çıkarılır.

Üçüncü aşama temizlemedir. Tamamen boş sütunlar, yinelenen kayıtlar ve fizyolojik olarak imkânsız değerler ele alınır. İmkânsız bir değer bulunduğunda satırı silmek yerine yalnızca o hücreyi boşaltmak tercih edilir; hastanın diğer bilgileri hâlâ kullanılabilir durumdadır. Hangi değer imkânsız sayılacağı klinik bir karardır.

3.2. Ayırım ve dönüşüm: Aşama 4 ile 5

Dördüncü aşama verinin eğitim ve sinama grubuna ayrılmasıdır ve ayırım hasta düzeyinde yapılmalıdır. Bir hastanın birden fazla yatışı bulunduğu satır düzeyinde ayırım, aynı hastayı iki gruba birden dağıtır; model o hastayı tanır ve sinama sonucu gerçekte olmayan bir yükselme

gösterir. Aynı sorun tıbbi görüntüde ve fizyolojik sinyalde de vardır: Aynı hastadan alınmış iki görüntü ya da iki sinyal parçası da ayrı gruplara düşmemelidir.

Beşinci aşama verinin modelin kullanabileceği biçime çevrilmesidir. Sayı olmayan bilgiler sayıya dönüştürülür, eksik değerler doldurulur ve sayısal sütunlar birbirine yakın ölçeklere getirilir. Bu dönüşümlerin nasıl yapılacağı yalnızca eğitim grubundan öğrenilmeli ve sınama grubuna aynen uygulanmalıdır. Eksik değerleri doldurmak için kullanılan ortanca bütün veriden hesaplanırsa, sınama grubundaki hastaların bilgisi öğrenme sürecine sızar.

Beşinci aşamanın dördüncüden sonra gelmesi bu yüzdendir. Sıra değiştiğinde ortaya çıkan hata sessizdir: Uyarı üretmez, sınama sonucunu bir miktar yükseltir ve kod okunduğunda mantıklı görünür.

3.3. Model ve ölçüm: Aşama 6 ile 8

Altıncı aşama modelin kurulması ve öğretilmesidir. Basit ve yorumlanabilir bir modelle başlanır; gerekçe başarım değil, üç özelliktir. Basit modelin neye baktığı okunabilir, olasılık üretir ve az veriyle ezberleme eğilimi düşüktür. Daha karmaşık bir model bunu aşabilir, ancak karşılaştırma ölçütü elde kalır.

Yedinci aşama tahmin üretme ve eşik seçimidir. Modelin sınıf etiketi değil olasılık üretmesi gerekir. Doğrudan etiket üreten bir model eşiği kendi varsayılanına sabitlemiş demektir ve o varsayılan klinik bir karar değildir. Eşiği klinik ekip belirler: Kaçırmanın pahalı olduğu bir problemde eşik düşürülür, yanlış alarmin pahalı olduğu bir problemde yükseltilir.

Sekizinci aşama ölçümdür ve bu derste en fazla yer ayrılan aşamadır. Altı başlık birlikte raporlanır: Güven aralığıyla ayırım gücü, kalibrasyon, seçilen eşikteki duyarlılık ve özgüllük ile kestirim değerleri, çalışma noktasının klinik karşılığı, alt grup dökümü ve hiçbir şey öğrenmeyen bir kuralla karşılaştırma. Bunlardan birinin eksik olması raporu yorumlanamaz hâle getirir.

3.4. Gerekçe, güvenlik ve uyumluluk: Aşama 9 ile 11

Dokuzuncu aşama kararın gerekçelendirilmesidir. Genel gerekçe modelin hangi bilgilere dayandığını, hasta düzeyinde gerekçe ise tek bir tahmini neyin sürüklediğini gösterir. Klinisyenin ihtiyaç duyduğu ikincisidir. Gerekçenin asıl kullanımı hata avıdır; doğruluk güvencesi değildir ve nedensellik iddiası taşımaz.

Onuncu aşama güvenlik bariyerlerinin kurulmasıdır. Üç bariyer birlikte çalışır: Model karar eşiğine çok yakın bir olasılık ürettiğinde çekimser kalır; eğitim popülasyonuna benzemeyen bir hasta geldiğinde tahmin üretmez; bilgilerinin büyük bölümü eksik olan bir hasta için karar önermez. Son madde en kolay atlanandır, çünkü doldurma işlemi bütün boşlukları ortalama değerlerle kapatır ve model hakkında hiçbir şey bilinmeyen bir hasta için kendinden emin bir sayı üretir.

On birinci aşama uyumluluk raporudur. Rapor sistemin amacını, kullanıcılarını, verisini, ölçülen başarımını, bariyerlerini, bilinen sınırlılıklarını, düzenleyici konumunu ve açık kalan sorularını kayda geçirir. Başarım sayıları ölçüm aşamasının çıktısından çekilir, elle yazılmaz.

3.5. Arayüz ve izleme: Aşama 12 ile 13

On ikinci aşama arayüz ve devreye almadır. Arayüz yalnızca bir sayı göstermemelidir; kararın kendisi, bariyerlerin durumu ve gerekçe birlikte sunulur. Bu yalnızca bir tasarım tercihi değildir. Sağlık profesyonelinin önerinin dayanağını bağımsız olarak gözden geçirebilmesi, yazılımın düzenleyici konumunu doğrudan etkiler. Demografik bilgiler gerekçe listesine karıştırılmaz; böyle bir katkı klinisyene sunulacak bir sebep değil, bir adalet denetimi bulgusudur.

On üçüncü aşama devreye alma sonrası izlemedir ve atölyede uygulanmaz. Başarım kayması ancak ölçülüyorsa fark edilir. Protokol, kodlama alışkanlığı veya hasta profili zamanla değişirken model sabit kalır ve başarım sessizce erir. İzlemesiz devreye alma, doğrulamasız devreye almaya yaklaşıp.

3.5. Yaşam döngüsü standartları

Yukarıdaki aşamalar, tıbbi cihaz yazılımı için kurulmuş uluslararası standartlarla örtüşür. IEC 62304 standardı tıbbi cihaz yazılımının yaşam döngüsü süreçlerini tanımlar ve yazılımı arıza hâlinde doğabilecek zarara göre A, B ve C güvenlik sınıflarından birine yerleştirir; gerekli belgelendirme, doğrulama ve sınama düzeyi bu sınıfa göre belirlenir [12]. Standardın tek normatif atfı, tıbbi cihazlarda risk yönetimini düzenleyen ISO 14971 standardıdır ve yazılıma özgü risk yönetimi gereklilikleri IEC 62304 içinde yedinci bölümde toplanmıştır [12, 13].

Makine öğrenmesinin kendine özgü riskleri için ISO 14971 sürecinin nasıl uygulanacağı ayrı bir rehberde ele alınmıştır. BS/AAMI 34971 belgesi, ISO 14971 sürecini değiştirmeksizin makine öğrenmesi içeren tıbbi teknolojilere uyarlanma biçimini tarif eder ve bu teknolojilerde yükselen ya da yalnızca bunlara özgü olan riskleri konu edinir [14].


Atölyede kurulacak prototip bu standartların gerektirdiği belgelendirmeyi üretmez. Ancak on birinci aşamada hazırlanan uyumluluk raporu, söz konusu belgelendirmenin hangi sorulara cevap vermesi gerektiğini gösterir.

4. Neden başarısız oluyorlar

4.1. Epic Sepsis Model vakası

Epic Sepsis Model, Amerika Birleşik Devletleri'nde yüzlerce hastanede kullanılan bir elektronik sağlık kaydı sistemine gömülü, tescilli bir sepsis erken uyarı modelidir ve klinisyene otomatik uyarı üretir. Michigan Medicine ekibi, 6 Aralık 2018 ile 20 Ekim 2019 tarihleri arasında 27.697 hastaya ait 38.455 yatış üzerinde modeli bağımsız olarak doğrulamıştır [7].

Çalışmanın bulguları şöyledir: Eğri altındaki alan 0,63 (yüzde 95 güven aralığı 0,62-0,64), duyarlılık yüzde 33, özgüllük yüzde 83, pozitif kestirim değeri yüzde 12 ve negatif kestirim değeri yüzde 95. Üreticinin belgelerinde belirtilen eğri altındaki alan aralığı ise 0,76 ile 0,83 arasındadır [7, 8].



Gerçekten sepsis olan hasta

Yanlış alarm **100 uyarının 88'i boşa bakılan hasta**

Wong ve ark. (2021) tarafından raporlanan yüzde 12 pozitif kestirim değerinin gösterimi.

Şekil 3. Yüzde 12 pozitif kestirim değerinin nöbet listesindeki karşılığı.

Pozitif kestirim değerinin yüzde 12 olması, klinik pratikte sistemin ürettiği yüz uyarının seksen sekizinin hastaya boşuna gidilmesiyle sonuçlanması demektir. Model raporlarında yüzde 83 özgüllük değeri iyi görünür; nöbet listesindeki karşılığı ise budur.


4.2. Üç yıl sonra, başka bir merkezde

Aynı ürün 2023 yılı boyunca iki ilçe acil servisinde, 145.885 başvuru üzerinde yeniden değerlendirilmiştir. Sepsis-3 tanımı kullanılmış ve uyarı üreticinin önerdiği eşik değerinde tetiklenmiştir. Bu çalışmada duyarlılık yüzde 14,7, özgüllük yüzde 95,3, pozitif kestirim değeri yüzde 7,6 ve negatif kestirim değeri yüzde 97,7 olarak bulunmuştur [9].

Buradaki ders belirli bir ürüne dair değildir. Hiçbir modelin başarımı, taşındığı yere kendiliğinden birlikte gelmez. Farklı hasta popülasyonu, farklı kodlama alışkanlığı ve farklı iş akışı, yayımlanmış başarımı geçersiz kılabilir.

4.3. Prevalans etkisi

Duyarlılık ve özgüllük sabit tutulduğunda dahi pozitif kestirim değeri, hastalığın ilgili klinikteki sıklığına bağlı olarak değişir. Bayes teoremi uyarınca pozitif kestirim değeri, duyarlılık ile prevalansın çarpımının; bu çarpım ile yanlış pozitif oranının hastalık görülme olasılığıyla çarpımının toplamına bölünmesiyle elde edilir.



Duyarlılık 0,33 ve özgüllük 0,83 sabit tutulmuştur. Eğri Bayes teoremiyle hesaplanmıştır.

Şekil 4. Duyarlılık ve özgüllük sabitken pozitif kestirim değerinin prevalansa bağlı değişimi.

Nadir bir durumu tarayan bir sistemde mükemmele yakın özgüllük bile yanlış alarm selini engellemez. Buradan çıkan pratik kural şudur: Kendisine bir karar destek sistemi önerilen klinisyenin soracağı ilk soru eğri altındaki alan değeri değil, kendi hasta grubundaki prevalans olmalıdır.

4.4. Alarm yorgunluğu ve otomasyon yanlılığı

Yanlış alarmın klinik maliyeti kümülatiftir. Uyarıların çoğu boşa çıktığında klinisyen uyarıyı okumadan kapatmayı öğrenir. Bu davranış doğru uyarıları da kapsar; sistem devrede görünmesine rağmen koruyucu etkisi sifıra yaklaşır. Literatürde bu durum alarm yorgunluğu olarak adlandırılır.

Ters yönde işleyen hata otomasyon yanlılığıdır. Klinisyen kendi muayene bulgusuna rağmen sistemin sessizliğini bir güvence olarak yorumlar ve kaçırılan vakada sorumluluğun kime ait olduğu bulanıklaşır. Bu iki hata birbirinin panzehiri değildir; aynı sistemde aynı anda görülebilir.

4.5. Modelin öğrendiği şey hastalık olmayabilir


Başarımın beklenenden düşük çıkmasının teknik nedenleri dört başlıkta toplanabilir. Birincisi kısayol öğrenmedir: Model, göğüs röntgeninde patolojiyi değil, belirli bir cihazın görüntüye bastığı işareti öğrenebilir. İkincisi hedef sızıntısıdır: Tahmin edilmek istenen sonucun bir sonucu, öznel olarak modele girebilir. Üçüncüsü dağılım kaymasıdır: Protokol veya hasta profili zamanla değişirken model sabit kalır. Dördüncüsü alt grup körlüğüdür: Toplam başarımlar kabul edilebilir görünürken belirli bir grupta belirgin biçimde düşük olabilir.

Bu dört durumun hiçbiri toplam doğruluk değerine bakılarak fark edilemez. Hepsisi ancak veri ve model açıkça sorgulanarak görülebilir ve 18 Eylül atölyesinin temel egzersizi tam olarak bu sorgulamadır.

5. Güvenilir kılan nedir

5.1. Ayrım gücü ile kalibrasyon aynı şey değildir

Ayrım gücü, modelin hasta olan bireyi olmayandan ayırabilme yeteneğini ölçer ve bir sıralama sorusudur. Kalibrasyon ise modelin verdiği olasılığın gerçekliğe karşılık gelip gelmediğini sorar: Model yüzde 20 risk dediği yüz hastanın gerçekten yirmisinde olay gerçekleşiyor mu?



Şematik gösterim. İki modelin eğri altı alanı aynı olabilir.

Şekil 5. Aynı ayrım gücüne sahip iki modelin farklı kalibrasyon davranışı.

İki model aynı eğri altındaki alan değerine sahip olabilir; bunlardan biri klinisyenin anlamlı bir eşik belirlemesine imkân verirken diğeri neredeyse tüm hastaları yüksek riskli gösterir. Klinik kararda bir eşik belirleniyorsa kalibrasyon, ayrım gücünden önceliklidir.

5.2. Açıklanabilirlik ne verir, ne vermez

Açıklanabilirlik yöntemlerinin klinik değerlendirmedeki en güçlü katkısı hata avıdır. Katkılar incelendiğinde modelin kararını hasta kayıt saatinin sürüklediği görülüyorsa bu bir sızıntı bulgusudur. Katkıların alt gruplar arasında belirgin biçimde farklılaşması adalet sorununun ilk işaretini verir.

Buna karşılık açıklanabilirlik nedensellik iddiası taşımaz ve doğruluk güvencesi sağlamaz; yanlış bir tahmin de ikna edici bir açıklama üretebilir ve açıklama bu durumda hatayı meşrulaştırabilir. Rudin, yüksek riskli kararlarda kara kutu modelleri açıklamaya çalışmak yerine baştan yorumlanabilir model kullanılmasını savunur [10]. Klinik bağlamda bu tartışma kapanmış değildir.

5.3. Raporlama standartları

Bir karar destek sistemine ilişkin iddianın denetlenebilir olması, ilgili raporlama standardının karşılanmasına bağlıdır.

Standart	Kullanım alanı	Künye
TRIPOD+AI	Klinik tahmin modeli geliştirme ve doğrulama çalışmaları	BMJ 2024;385:e078378
PROBAST+AI	Tahmin modeli çalışmalarında yanlılık riski değerlendirmesi	BMJ 2025;388:e082505
DECIDE-AI	Karar destek sistemlerinin erken evre klinik değerlendirmesi	Nat Med 2022;28:924-933
CONSORT-AI	Yapay zekâ müdahalesini test eden randomize çalışmalar	BMJ 2020;370:m3164
SPIRIT-AI	Aynı çalışmaların protokol aşaması	BMJ 2020;370:m3210

Bu listelerin pratik kullanımı şöyledir: Bir karar destek sistemi önerildiğinde, ilgili kontrol listesindeki maddelerin kaçının cevaplandığı sorulur. Cevaplanmayan her madde bir belirsizlik kalemi olarak kayda geçer.

5.4. İnsan gözetiminin tasarımı

İnsan gözetimi bir slogan değil, somut bir tasarım kararları kümesidir. Eşik seçimi klinik bir karardır; hangi duyarlılık ve özgüllük dengesinin kabul edilebilir olduğunu model değil klinik ekip belirler. Model, güven aralığı geniş olduğunda tahmin üretmemeyi seçebilmelidir. Eğitim verisine benzemeyen bir hasta geldiğinde sistem sessizce tahmin üretmemelidir. Kararın hangi durumlarda insana devredileceği önceden yazılmış olmalıdır.

6. Düzenleyici çerçeve

6.1. Bu bir tıbbi cihaz mı

Bir yazılım, üretici tarafından teşhis veya tedaviye yönelik bir amaçla piyasaya sürülüyorsa tıbbi cihaz mevzuatı kapsamına girer. Avrupa Birliği'nde bu değerlendirme Tıbbi Cihaz Tüzüğü (AB 2017/745) ve özellikle yazılımı sınıflandıran Kural 11 üzerinden yapılır [11]. Cevabın olumsuz olması sorumluluğun ortadan kalktığı anlamına gelmez; yalnızca sorumluluğun hangi mevzuat katmanından doğacağını değiştirir.

6.2. Avrupa Birliği

Avrupa Birliği Yapay Zekâ Yasası (AB 2024/1689) 1 Ağustos 2024 tarihinde yürürlüğe girmiştir. Dijital Omnibus düzenlemesi (AB 2026/1744) ise 24 Temmuz 2026 tarihinde yayımlanmış ve 27 Temmuz 2026 tarihinde yürürlüğe girmiştir [15, 16].



AB 2026/1744 sayılı Dijital Omnibus düzenlemesi son iki tarihi ertelenmiştir.

Şekil 6. AB Yapay Zekâ Yasası uyum takvimi, Temmuz 2026 düzenlemesinden sonraki hâliyle.

Bu düzenleme ile Ek III kapsamındaki bağımsız yüksek riskli sistemlere ilişkin yükümlölükler 2 Aralık 2027 tarihine, ürün güvenliği mevzuatı kapsamındaki ürünlere gömülü Ek I sistemlerine ilişkin yükümlölükler ise 2 Ağustos 2028 tarihine ertelenmiştir. Tıbbi cihaz mevzuatı kapsamındaki yapay zekâ bileşenleri Ek I grubunda yer alır. Madde 50 kapsamındaki şeffaflık yükümlölükleri ertelenmemiş ve 2 Ağustos 2026 tarihinde yürürlüğe girmiştir [16].

6.3. Amerika Birleşik Devletleri

Amerikan Gıda ve İlaç Dairesi tarafından 1995 yılından bu yana yaklaşık 1.450 yapay zekâ destekli cihaz pazarlama yetkisi almıştır. Cihazların çoğunluğu radyoloji, kardioloji ve nöroloji alanlarındadır ve büyük bölümü 510(k) yolunu izlemiştir. Bugüne kadar üretken yapay zekâ veya büyük dil modeliyle çalışan hiçbir cihaz yetkilendirilmemiştir [5]. Bu listenin kurum tarafından kapsamlı bir envanter olmadığı açıkça belirtilmektedir; sayılar indirme tarihine göre değişir ve kesin bir rakam olarak sunulmamalıdır.

Öğrenen sistemlerin yasal biçimde güncellenebilmesi, Aralık 2024 tarihli nihai kılavuzla düzenlenen önceden belirlenmiş değişiklik kontrol planı mekanizmasına bağlanmıştır [17].

6.4. Türkiye

Türkiye'de yapay zekâyı doğrudan düzenleyen müstakil bir kanun bulunmamaktadır. Bu durum sorumluluğun belirsiz olduğu anlamına gelmez; sorumluluk mevcut mevzuat katmanlarının birlikte uygulanmasıyla belirlenir.

Katman	Sağlıkta yapay zekâ açısından karşılığı
Tıbbi cihaz mevzuatı	Yazılımın cihaz sayılıp sayılmadığı, kayıt ve piyasaya arz koşulları
6698 sayılı Kanun	Sağlık verisi özel nitelikli kişisel veridir; işleme şartları ve otomatik karar boyutu
Tıbbi malpraktis rejimi	Hekimin ve sağlık kuruluşunun sorumluluğu, aydınlatılmış onamın kapsamı
2026/9 sayılı Genelge	Türkiye Yapay Zekâ Eylem Planı ve kamu kurumlarına yüklenen görevler

Mevzuat hareketli bir alandır. Bu bölümdeki değerlendirme Eylül 2026 itibarıyla geçerlidir ve hukuki görüş niteliği taşımaz.

7. Atölyeye köprü

Üretken yapay zekâ araçlarının yaygınlaşmasıyla kod yazma maliyeti belirgin biçimde düşmüştür. Klinik bir fikri olan ve Python bilmeyen bir araştırmacı, birkaç saat içinde çalışan bir karar destek sistemi üretebilir. Yazma maliyeti düşerken doğrulama maliyeti düşmemiştir.

Atölye bu imkânı doğrudan sunar. Katılımcılar altı defter boyunca kod yazmaz. Her adımda sade bir klinik dille yazılmış bir istem verilir; katılımcı bunu bir üretken yapay zekâ aracına aktarır, aracın ürettiği kodu deftere yapıştırır ve çalıştırır. Python bilgisi gerekmez.

Her istemin sonunda beklenen sonuç yazılıdır: Kodun hangi adla hangi bilgiyi üretmesi gerektiği. Yapıştırmanın ardından gelen kontrol hücresi tam olarak bunu sınar ve eksik bulursa bildirir. Katılımcı bildirimi araca geri verip kodu yeniden üretir. Denetim sorumluluğu böylece kullanıcıya kalır ve bu, atölyenin asıl öğrettiği alışkanlıktır.

Yazılan kod defterden deftere taşınır. Her defterin sonunda o ana kadar üretilmiş bütün adımlar tek bir blok hâlinde toplanır ve bir sonraki defterin ilk hücresine yapıştırılır. Altıncı defterin sonunda biriken kod, web arayüzü arkasında çalışan eksiksiz bir klinik karar destek sistemidir.

Üretken araçların sağlık bağlamında üç tipik hatası bulunur. Birincisi uydurulmuş klinik eşiktir: Model, kaynağı bulunmayan bir kesme değerini kendinden emin bir dille koda yazar. İkincisi sessiz sızıntıdır: Üretilen kod, farkında olunmadan sınama verisini öğrenme sürecine karıştırabilir. Üçüncüsü halüsinasyon kaynaktır: Var olmayan bir makaleye yapılan atıf, biçimsel olarak doğru görüldüğü için en tehlikeli çıktıdır. Atölyedeki kontrol hücreleri ve istemlerdeki beklenen sonuç bölümleri bu üç riski hedefler.

Her adımdan sonra kısa bir Python notu gelir. Notlar hiçbir ön bilgi varsaymaz ve katılımcının az önce gördüğü yapıyı açıklar: Kütüphane nedir, tablo nedir, fonksiyon ve açıklama metni ne işe yarar, ekrana yazmak ile geri vermek arasındaki fark nedir, sözlük ve döngü nasıl okunur. Amaç katılımcıya kod yazdırmak değil, gelen kodu okuyabilir hâle getirmektir.

Katılımcılar altı hazır veri kümesinden birini seçer. Üçü tablo ve sinyal biçiminde gerçek klinik veridir: MIMIC-IV demo yoğun bakım kaydı, Breast Cancer Wisconsin kümesi ve MIMIC-IV-ECG demo kayıtları. İkiisi açık erişimli tıbbi görüntü kümesidir. Altıncısı klinik metindir ve kimlik doğrulaması istemeyen bir Türkçe klinik not kümesi bulunmadığından bu yolda veri üretilir. Hepsisi şifre istemez ve tarayıcı üzerinden doğrudan alınır.

Seçim ne olursa olsun veri yükleme adımı aynı yapıda bir sonuç üretir: Hasta kimliği ve hedef sütunlarını içeren bir tablo. Ortak yapı sayesinde sonraki bütün adımlar veri türünden bağımsız olarak aynı şekilde ilerler. Elektrokardiyografi kümesi ile yoğun bakım kümesi aynı hastaları içerdiğinden, o yolu seçen katılımcı aynı sonucu bu kez sinyalden tahmin eder ve iki yaklaşım karşılaştırılabilir hâle gelir.

8. Kapanış

Oturumdan çıkarılması beklenen beş sonuç şunlardır. Karar destek sistemi teşhis koymaz; klinik dikkati yönlendirir. Bir sistemin kurulması on üç aşamadan geçer ve hataların çoğu ilk beş aşamada, yani karar anının tanımlanması ile verinin hazırlanması sırasında yapılır. Dış doğrulaması bulunmayan bir başarıım iddiası yalnızca bir iddiadır. Açıklanabilirlik hata bulmak

için güçlü bir araçtır, ancak doğruluk güvencesi değildir. Üretken yapay zekâ kod yazar, sorumluluk almaz.

Kaynaklar

- [1] 2026/9 sayılı Cumhurbaşkanlığı Genelgesi, Türkiye Yapay Zekâ Eylem Planı (2026-2030). Resmî Gazete, 18 Ağustos 2026, Sayı 33344.
- [2] T.C. Sanayi ve Teknoloji Bakanlığı. Türkiye Yapay Zekâ Eylem Planı (2026-2030).
- [3] Osheroﬀ JA, Teich JM, Levick D, Saldana L, Velasco FT, Sittig DF, Rogers KM, Jenders RA. Improving Outcomes with Clinical Decision Support: An Implementer's Guide. 2. baskı. HIMSS; 2012.
- [4] Campbell R. The five rights of clinical decision support. Journal of AHIMA. 2013;84(10):42-47.
- [5] Congressional Research Service. FDA Regulation of AI-Enabled Devices. In Focus IF13245; 2026.
- [6] U.S. Food and Drug Administration. Clinical Decision Support Software: Guidance for Industry and Food and Drug Administration Staff. Eylül 2022.
- [7] Wong A, Otlis E, Donnelly JP, Krumm A, McCullough J, DeTroyer-Cooley O, Pestue J, Phillips M, Konye J, Penosa C, Ghous M, Singh K. External validation of a widely implemented proprietary sepsis prediction model in hospitalized patients. JAMA Internal Medicine. 2021;181(8):1065-1070. doi:10.1001/jamainternmed.2021.2626
- [8] Habib AR, Lin AL, Grant RW. The Epic sepsis model falls short: the importance of external validation. JAMA Internal Medicine. 2021;181(8):1040-1041. doi:10.1001/jamainternmed.2021.3333
- [9] Ostermayer DG, Braunheim B, Mehta AM, Ward J, Andrabi S, Sirajuddin AM. External validation of the Epic sepsis predictive model in 2 county emergency departments. JAMIA Open. 2024;7(4):ooae133. doi:10.1093/jamiaopen/ooae133
- [10] Rudin C. Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead. Nature Machine Intelligence. 2019;1:206-215. doi:10.1038/s42256-019-0048-x
- [11] Regulation (EU) 2017/745 on medical devices (MDR), Ek VIII, Kural 11.
- [12] IEC 62304:2006/AMD1:2015. Medical device software - Software life cycle processes.
- [13] ISO 14971:2019. Medical devices - Application of risk management to medical devices.
- [14] BS/AAMI 34971:2023. Guidance on the application of ISO 14971 to artificial intelligence and machine learning.
- [15] Regulation (EU) 2024/1689 laying down harmonised rules on artificial intelligence (AI Act). OJ, 12 Temmuz 2024.
- [16] Regulation (EU) 2026/1744 (Digital Omnibus on AI). OJ, 24 Temmuz 2026.
- [17] U.S. Food and Drug Administration. Marketing Submission Recommendations for a Predetermined Change Control Plan for Artificial Intelligence-Enabled Device Software Functions. Nihai kılavuz, 4 Aralık 2024.

Teşekkür

Bu oturum, TÜBİTAK destekli Sağlık Bilimlerinde Teknoloji ve Yapay Zekâ Okuryazarlığı Eğitimi projesi kapsamında Akdeniz Üniversitesi ev sahipliğinde gerçekleştirilmiştir. Davet ve organizasyon için proje yürütücülerine ve düzenleme kuruluna teşekkür edilmektedir.

Ders ve atölye materyalinin tamamı açık depo olarak yayımlanmaktadır:
github.com/utkukose/cdss-genai-NB-lecture